#### Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks

Patrick Lewis, Ethan Perez, Aleksandra Piktus, Fabio Petroni, Vladimir Karpukhin, Naman Goyal, Heinrich Küttler, Mike Lewis, Wen-tau Yih, Tim Rocktäschel, Sebastian Riedel, Douwe Kiela

Facebook Al Research, University College London, New York University

NeurlPS 2020 2024.05.27

> 발제자: 윤예준




## 연구

- Parametric knowledge Bases: T5, GPT-3
  - → 외부 지식 접근 없이 추론 가능
  - → 지식 확장 및 수정 어려움
  - → hallucination 발생 가능
- Non-Parametric Knowledge Bases: REALM, ORQA
  - → 지식 수정 가능
  - → answer를 생성하는 것이 아니기 때문에 answer 범위 제한

Pre-trained parametric와 Non-parametric memory를 결합한 Language Generation Model 제안


#### Method - Overview

- RAG(Retrieval-Augmented Generation) Model
  - Step 1: Query가 들어오면 Query Encoder를 통해 q(x) 생성
  - Step 2: MIPS(Maximum Inner Product Search) 이용 q(x)와 가장 가까운 Top-k개의 Document 탐색
  - Step 3: Query와 Document를 concat하여 Generator 입력으로 사용
  - Step 4: 각 concat(Query, Document)간 Generator 출력을 Marginalize하여 최종 출력 생성



- Query Encoder: DPR Query Encoder BERT Base
- Retriever: DPR Document Encoder BERT Base
- Generator: BART Large

# Method - Overview



#### Method - Model

RAG-Sequence Model

$$p_{\text{RAG-Sequence}}(y|x) \approx \sum_{z \in \text{top-}k(p(\cdot|x))} p_{\eta}(z|x) p_{\theta}(y|x,z) = \sum_{z \in \text{top-}k(p(\cdot|x))} p_{\eta}(z|x) \prod_{i}^{N} p_{\theta}(y_{i}|x,z,y_{1:i-1})$$


RAG-Token Model

$$p_{ ext{RAG-Token}}(y|x) pprox \prod_{i}^{N} \sum_{z \in ext{top-}k(p(\cdot|x))} p_{\eta}(z|x) p_{\theta}(y_i|x, z_i, y_{1:i-1})$$

- Marginalize 방법에 따라 두 가지 모델 제안
- RAG-Sequence: 각 document마다 sequence 생성 후 marginalize
- RAG-Token: 토큰 생성 마다 marginalize


# Method – RAG-Sequence Model

#### • Train



# Method – RAG-Sequence Model


- Decoding
  - Sequence를 끝까지 생성 후 document에 대해 marginalize 진행 -> 기존의 beam search 적용 불가
  - 해결 방법: 각 document 별로 beam search 적용
  - 문제점: beam search 과정에서 생성되지 않은 확률 존재
    - → 존재하지 않은 경우 additional forward pass 진행



• 위 방법은 긴 sequence일수록 매우 비효율적 → Fast Decoding 제안

## Method - RAG-Token Model

Train



• 기존 Decoding 방법 사용 가능

## Open-Bomain Question Answering

NQ: Natural Questions, TQA: TriviaQA, WQ: WebQuestions, CT: CuratedTrec

	Model	NQ	TQA	WQ	СТ
Closed	T5-11B [52]	34.5	- /50.1	37.4	-
Book	T5-11B+SSM[52]	36.6	- /60.5	44.7	
Open	REALM [20]	40.4	- / -	40.7	46.8
Book	DPR [26]	41.5	<b>57.9</b> / -	41.1	50.6
	RAG-Token RAG-Seq.		55.2/66.1 56.8/ <b>68.0</b>	<b>45.5</b> 45.2	50.0 <b>52.2</b>

- 외부 지식을 사용하지 않은 Closed-Book setting보다 월등히 좋은 성능
- Retrieval과 Extractive system에 의존하는 Open Book setting보다 좋은 성능
- 검색된 문서에 정답이 없는 경우에도 정답 생성 가능을 보임 (RAG: 11.8% vs Extractive model: 0%)

- Knowledge Intensive Tasks
  - Jeopardy Question Generation: 주어진 정답 entity를 가지고 그 정답에 상응하는 질문을 생성하는 task

r <u></u>							Task	Input	Model	Generation	
Model	Jeo <sub>j</sub> B-1	pardy QB-1	MSM. R-L	ARCO B-1	FVR3 Label	FVR2 Acc.	MS-	define middle ear	RAG-1	<sup>?</sup> The middle ear is the part of the ear between the middle ear and the nose.  The middle ear is the portion of the ear internal to the eardrum.  The middle ear includes the tympanic cavity and the three ossicles.	
SotA	1-	=	49.8*	49.9*	76.8	92.2*	MARCO	what currency needed in scotland	RAG-T	The currency needed in Scotland is Pound sterling.  Pound is the currency needed in Scotland.  The currency needed in Scotland is the pound sterling.	
BART	15.1	19.7	38.2	41.6	64.0	81.1			BART	<sup>?</sup> This state has the largest number of counties in the U.S.	
RAG-Tok.	17.3	22.2	40.1	41.5	72.5	89.5	Question	Washington		It's the only U.S. state named for a U.S. president It's the state where you'll find Mount Rainier National Park	
RAG-Seq.	14.7	21.4	<u>40.8</u>	<u>44.2</u>	12.3	<u> </u>	Gener -ation	The Divine BART		*This epic poem by Dante is divided into 3 parts: the Inferno, the Purgatorio & the Purgatorio & Toante's "Inferno" is the first part of this epic poem	
								Comedy		This 14th century work is divided into 3 sections: "Inferno", "Purgatorio" & "Paradiso"	

- Abstractive Question Answering & Jeopardy Question Generation & Fact Verification
  - BART보다 좋은 성능 + 적은 hallucination + 다양성↑
  - SotA: 정답과 관련성이 높은 문서를 직접 입력 -> Retrieval 없이 gold passage가 입력됨

# 결 과

Model	NQ	TQA Exact	WQ Match	CT	Jeopa B-1	rdy-QGen QB-1	MSM R-L	Aarco B-1	FVR-3 Label A	FVR-2 accuracy
RAG-Token-BM25 RAG-Sequence-BM25	29.7 31.8	41.5 44.1	32.1 36.6	33.1 33.8	17.5 11.1	22.3 19.5	55.5 56.5	48.4 46.9	75.1	91.6
RAG-Token-Frozen RAG-Sequence-Frozen	37.8 41.2	50.1 52.1	37.1 41.8	51.1 52.6	16.7 11.8	21.7 19.6	55.9 56.7	49.4 47.3	72.9	89.4
RAG-Token RAG-Sequence	43.5 <b>44.0</b>	54.8 <b>55.8</b>	<b>46.5</b> 44.9	51.9 <b>53.4</b>	<b>17.9</b> 15.3	<b>22.6</b> 21.5	56.2 <b>57.2</b>	<b>49.4</b> 47.5	74.5	90.6


- RAG의 Retriever를 BM25로 교체
  - → 대부분 task에서 낮은 성능
  - → FEVER에선 높은 성능: FEVER의 claim이 entity-centric이기 때문
- Retriever Freeze: Generator만 학습 → Retriever로 같이 학습하는 것이 효과적
- Knowledge base 변경에 따른 성능 변화
  - 각국 지도자를 맞추는 task: "Who is {position}?" (e.g. Who is the President of Pero?")
  - 단순히 non-parametric memory만 변경함으로써 RAG의 world knowledge를 변경할 수 있음을 보임

ACC	2016 wiki	2018 wiki			
2016 leader	70%	4%			
2018 leader	12%	68%			

• RAG-+0ken model로 Hemingway를 입력으로 질문 생성 시 posterior  $p(z_i|x,y_i,y_{-i})$  시각화


**Document 1**: his works are considered classics of American literature ... His wartime experiences formed the basis for his novel "A Farewell to Arms" (1929) ...

**Document 2**: ... artists of the 1920s "Lost Generation" expatriate community. His debut novel, "The Sun Also Rises", was published in 1926.



- 각 책 제목을 생성할 때 관련된 문서에 높은 점수 부여
- 책 제목의 첫 토큰을 생성하면 특정 문서에 덜 집중 → parametric knowledge 이용 추정

• Retrieving more documents 효과 (왼쪽부터 A, B, C)



- (A,B): RAG-Seq의 경우 Retrieved Docs가 많을수록 성능 개선
- (A,B): RAG-TOK의 경우 Retrieved Docs가 일정 수 이상되면 성능 저하
- (C): Abstractive Answer Generation의 경우 많은 Docs가 필요하지 않음

- <u>로</u> Pre-tr<del>ain</del>ed parametric와 Non-parametric memory를 결합한 Language Generation Model 제안
- Non-parametric memory를 통해 LM의 지식 수정 가능
- Generator로 인해 다양한 출력 생성 가능

# Open

- Questions RAG-Seq, RAG-Token이랑 성능이 다른데 어떻게 이를 선택하는 것이 좋을까?
- Retrieved Docs가 많을 수록 성능 개선이 될 것 같은데 왜 안되는가?

감사합니 다.