



HUMANE Paper Review

Stay Focused: Problem Drift in Multi-Agent Debate

**Jonas Becker^{1,2,*}, Lars Benedikt Kaesberg¹, Andreas Stephan³,
Jan Philip Wahle¹, Terry Ruas¹, Bela Gipp¹**

¹University of Göttingen, Germany; ²LKA NRW, Germany; ³University of Vienna, Germany

*Correspondence: jonas.becker@uni-goettingen.de

숭실대학교 문화콘텐츠학과, 석사과정생 이다현

2026 EACL findings

2026.04.09

Background

- Multi-Agent Debate, MAD
 - 왜 등장했을까? – 단일 LLM의 한계 – 답의 다양성, 모듈성, 자기비판 능력
 - 여러 에이전트가 서로 토론하게 하면 더 좋은 추론과 문제 해결이 가능할 것이다.

Related works

- MAD의 효과를 강조하는 연구
 - 다양한 persona를 부여한 에이전트들이 토론하면서 reasoning, 창의적 글쓰기, dialogue generation, theory of mind 등을 개선할 수 있다는 흐름
 - self-consistency나 self-correction 같은 장치와 결합해 MAD의 효과를 보여줌
- MAD의 한계를 비판하는 연구
 - multi-turn generative setting에서 성능이 체계적으로 떨어진다고 보고
 - 계산비용 대비 single-agent prompting이 더 낫거나 비슷할 수 있다고 주장
 - self-critique 구조가 planning을 오히려 해칠 수 있다는 지적
 - LLM이 만들어내는 비판이 실제 성능 향상과 무관할 수 있다는 비판

Gap

- MAD는 길게 할수록 좋을까?
 - 아니다; hallucination 전파 2) agent orchestration 문제 3) planning 저하 4) 비효율
 - 그러나 충분히 분석되지 않았다.
 - 기존 연구는 MAD의 성능 평균만 봤고, 이 연구는 토론 내부에서 문제가 어떻게 drift되는지를 처음으로 구조적으로 분석
- 길어질수록 Problem Drift가 생긴다. 즉 처음 문제에서 벗어나 성능이 떨어진다.

Contribution

1. problem drift라는 개념을 새롭게 정의, FOCUS로 측정
2. 10개 데이터셋, 4개 도메인에서 problem drift의 보편성을 실증
3. test-time detection/mitigation baseline을 제안

Problem Drift

- 정의: 토론이 진행될수록 에이전트가 초기 문제에서 벗어나 성능이 체계적으로 감소하는 현상
- 중요한 점: 단순 오답이 아니라 “토론 과정 속 성능 붕괴”를 본다
- 즉 final answer보다 discussion trajectory가 분석 대상

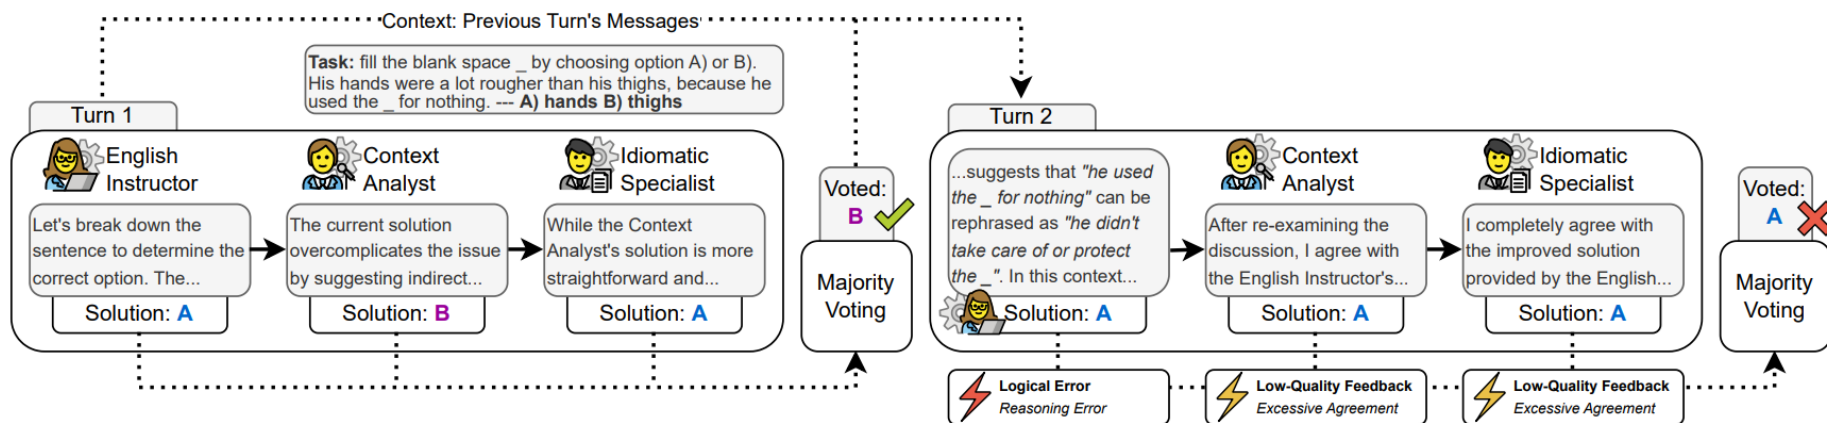


Figure 2: Example of problem drift in MAD. The *English instructor* induces a logical error in the discussion. The other agents agree without skepticism, leading to the wrong solution and problem drift.

How is drift measured?

$$FOCUS_r = M(\hat{y}^{(r)}, y) - M(\hat{y}^{(r-1)}, y) \in [-1, 1]$$

- 각 턴에서 나온 답의 품질이 이전 턴보다 얼마나 좋아지거나 나빠졌는지를 FOCUS로 측정
- $FOCUS < 0$: 이번 턴에서 성능 하락 / $FOCUS > 0$: 성능 개선
- 연속된 음수 FOCUS의 누적 = problem drift
- 이후 다시 이전 성능 이상으로 회복하면 recovery

Methodology

- Experiment setup = Debate setup
 - 에이전트 수 3명, 서로 다른 expert persona 부여
 - 총 7 turns 토론, 각 turn마다 메시지와 현재 기준 답을 제시
 - 모든 에이전트는 서로의 메시지를 보고, disagreement 시 새로운 답을 제안
 - 기본 의사결정은 Voting, 추가로 Consensus도 실험해 일반화 점검

Methodology

- DRIFTJudge: gold 없이 판정하려는 test-time detector
 - 현재 턴과 다음 턴을 비교
 - 형식은 LLM-as-a-judge
 - 더 강한 judge를 쓰지 않고 에이전트와 같은 모델을 judge로 사용
 - 의도: 성능 향상이 모델 능력 차이가 아니라 구조 변화 때문인지 보이기 위함

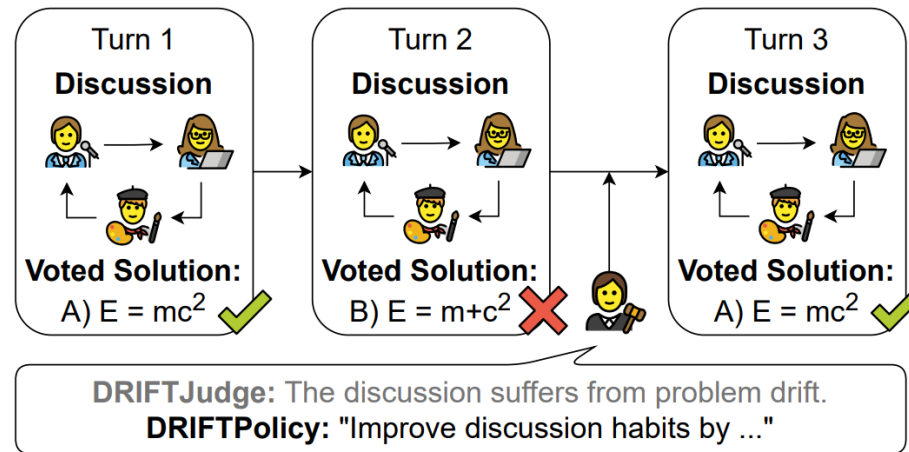


Figure 1: Problem drift in MAD. **DRIFTJudge** detects problem drift at test-time. **DRIFTPolicy** provides on-demand feedback about the conversation.

Methodology

- Regenerate
 - drift가 난 turn을 되돌리고
 - non-zero temperature로 한 번 다시 생성
 - direct but brute-force
- DRIFTPolicy
 - 네 번째 agent가 들어와
 - 현재 토론의 문제점을 짚고 개선 피드백 제공
 - targeted feedback

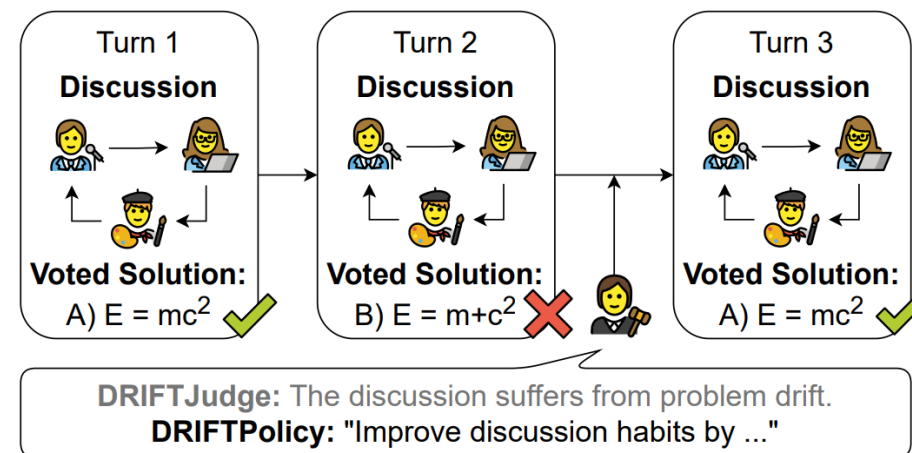


Figure 1: Problem drift in MAD. **DRIFTJudge** detects problem drift at test-time. **DRIFTPolicy** provides on-demand feedback about the conversation.

Methodology

- Experiment setup
 - Generative: XSum, ETPC, WMT19
 - Reasoning: StrategyQA, WinoGrande, AQUA-RAT
 - Knowledge: ETHICS, MMLU-Pro, GPQA
 - Instruction-following: IFEval
 - 평가: 객관식 accuracy, 생성 BERTScore, IFEval strict accuracy

RQ1. 긴 토론은 성능을 개선하는가, 악화시키는가?

- 상당수 샘플 악화: 4.7%~69.9%
- 특히 생성 과제에서 긴 토론의 부작용이 크게 나타남

		# of samples staying at high perf. $P(\hat{y}^{(r)}, y) > 0.7 \forall r$	# of samples staying at low perf. $P(\hat{y}^{(r)}, y) < 0.7 \forall r$	# of improving samples $FOCUS_{1,r} > 0$	# of worsening samples $FOCUS_{1,r} < 0$	Total Samples
Generative	ETPC	2.0% (22)	1.9% (21)	26.5% (287)	69.5% (753)	1,083
	XSum	0.3% (3)	7.9% (91)	37.9% (438)	54.1% (626)	1,158
	WMT19	14.0% (143)	3.0% (31)	13.2% (135)	69.9% (714)	1,023
Reasoning	StrategyQA	72.2% (715)	18.3% (181)	3.7% (37)	5.8% (57)	990
	WinoGrande	63.4% (561)	21.3% (188)	6.8% (60)	8.6% (76)	885
	AQUA-RAT	70.5% (537)	21.0% (160)	3.8% (29)	4.7% (36)	762
Knowledge	GPQA	33.2% (225)	49.9% (338)	8.1% (55)	8.7% (59)	677
	MMLU-Pro	51.7% (578)	35.7% (399)	4.0% (45)	8.7% (97)	1,119
	ETHICS	64.0% (675)	22.0% (232)	5.7% (60)	8.2% (86)	1,053
IF	IFEval	60.4% (898)	21.7% (323)	6.1% (90)	11.8% (175)	1,486

Table 1: Percentage (number) of samples measured across debate rounds $r \in [1, \dots, 7]$. Left cells: **green** indicates examples where *performance remains* > 0.7 (second column); **red** indicates examples where *performance remains* < 0.7 (third column). We set 0.7 as a threshold because it is close to the average performance across tasks. Right cells: **green** indicates examples improving over round 1 (*positive FOCUS*, fourth column); **red** indicates examples degrading over round 1, i.e, problem drift (*negative FOCUS*, fifth column). Cell opacity increases with percentage. MAD uses *Llama-3.1* and Voting. Results with *gpt-5-mini* (Singh et al., 2025) are in Table 9 of Appendix G.

RQ2. problem drift는 얼마나 자주 발생하는가?

- 생성 과제: ETPC 88.6%, XSum 74.6%, WMT19 76.3%로 매우 높음
- 반면 reasoning/knowledge는 6.6%~15.5% 수준으로 낮음
- 하지만 객관식에서 drift가 나면 맞던 답이 완전히 틀리는 식으로 더 치명적

	Dataset	Drifting Samples (%)	Recovery Rate (%)	Avg. Turns $FOCUS_r < 0$
Generative	ETPC	88.6 ± 0.8	19.8 ± 1.8	2.23 ± 0.04
	XSum	74.6 ± 0.7	19.0 ± 1.0	1.29 ± 0.07
	WMT19	76.3 ± 2.7	8.5 ± 0.3	1.42 ± 0.05
Reasoning	StrategyQA	6.6 ± 0.6	18.5 ± 5.7	0.07 ± 0.00
	WinoGrande	14.9 ± 1.8	39.4 ± 4.8	0.17 ± 0.03
	AQUA-RAT	8.4 ± 2.1	39.1 ± 4.4	0.09 ± 0.02
Knowledge	GPQA	13.3 ± 1.1	23.3 ± 3.0	0.14 ± 0.01
	MMLU-Pro	13.1 ± 0.6	25.9 ± 7.8	0.14 ± 0.00
	ETHICS	15.5 ± 1.2	45.4 ± 5.4	0.18 ± 0.01
IF	IFEval	20.8 ± 1.7	44.7 ± 4.9	0.25 ± 0.02

Table 2: Statistics showing the percentage of **Drifting Samples** at any point in the debate, the percentage of **Recovering Samples** relative to the drifting ones, and the average number of turns after which problem drift occurs $FOCUS_r \neq 0$. The highest and lowest values per column are displayed in **bold**. Values are reported with their respective standard deviations for three runs. MAD uses *Llama-3.1* and Voting.

RQ3. drift가 생겨도 다시 회복할 수 있는가?

- 회복률: drift가 발생한 샘플들 중에서 이후 다시 원래 수준 이상으로 돌아온 비율
- IFEval 44.7%, ETHICS 45.4%는 비교적 회복이 잘 됨
- 복잡 reasoning은 낮음: StrategyQA 18.5%
- 주관적 생성은 더 낮음: WMT19 8.5%
- 즉 한 번 길을 잃으면, 복잡하거나 주관적인 과제에서 잘 못 돌아온다

	Dataset	Drifting Samples (%)	Recovery Rate (%)	Avg. Turns $FOCUS_r < 0$
Generative	ETPC	88.6 ± 0.8	19.8 ± 1.8	2.23 ± 0.04
	XSum	74.6 ± 0.7	19.0 ± 1.0	1.29 ± 0.07
	WMT19	76.3 ± 2.7	8.5 ± 0.3	1.42 ± 0.05
Reasoning	StrategyQA	6.6 ± 0.6	18.5 ± 5.7	0.07 ± 0.00
	WinoGrande	14.9 ± 1.8	39.4 ± 4.8	0.17 ± 0.03
	AQUA-RAT	8.4 ± 2.1	39.1 ± 4.4	0.09 ± 0.02
Knowledge	GPQA	13.3 ± 1.1	23.3 ± 3.0	0.14 ± 0.01
	MMLU-Pro	13.1 ± 0.6	25.9 ± 7.8	0.14 ± 0.00
	ETHICS	15.5 ± 1.2	45.4 ± 5.4	0.18 ± 0.01
IF	IFEval	20.8 ± 1.7	44.7 ± 4.9	0.25 ± 0.02

Table 2: Statistics showing the percentage of **Drifting Samples** at any point in the debate, the percentage of **Recovering Samples** relative to the drifting ones, and the average number of turns after which problem drift occurs $FOCUS_r \neq 0$. The highest and lowest values per column are displayed in **bold**. Values are reported with their respective standard deviations for three runs. MAD uses *Llama-3.1* and Voting.

RQ4. 인간은 drift의 원인을 무엇이라 보는가?

- 가장 흔한 원인: lack of progress 35% (170개 중 60건)
- 저자들은 원인을 temporal error와 local error로 구분
- 즉 drift는 한 번의 오답보다 “대화 품질 붕괴”와 연결됨

Category	Error Type	Explanation	Cases
Temporal	Lack of Progress	Inefficiency, Redundancy, Circular discussion, Repetition, Unproductive disagreement	60
	Low-Quality Feedback	Excessive criticism, Excessive agreement, Self-contradictory feedback, Unhelpful feedback	45
	Low-Quality Engagement	Poor collaboration, Minimal participation, Disjointed contribution, Ignorance	25
Local	Lack of Clarity	Overanalysis, Overgeneralization, Insignificant changes	43
	Task Non-Compliance	Off-topic, Bad instruction following	35
	Knowledge Gap	Assumptions, Lack of data, Hallucinated facts, Wrongly cited	28
	Logical Error	Lack of common sense, Reasoning error	28
	Linguistic Error	Fluency, Grammatical errors, False pronouns	23
None of these		No problem drift	29
Other		Any other error	8

Table 3: Error types that occur with problem drift. Eight human experts assessed a total of 170 discussion excerpts to determine how frequently each error type occurs.

RQ4. 인간은 drift의 원인을 무엇이라 보는가?

- 에러 taxonomy를 어떻게 이해할까?
 - 반복과 무의미한 criticism이 자주 같이 나타남
 - 즉 새 정보가 없는 상태에서 괜히 고치려는 행동이 성능을 깎는다

Category	Error Type	Explanation	Cases
Temporal	Lack of Progress	Inefficiency, Redundancy, Circular discussion, Repetition, Unproductive disagreement	60
	Low-Quality Feedback	Excessive criticism, Excessive agreement, Self-contradictory feedback, Unhelpful feedback	45
	Low-Quality Engagement	Poor collaboration, Minimal participation, Disjointed contribution, Ignorance	25
Local	Lack of Clarity	Overanalysis, Overgeneralization, Insignificant changes	43
	Task Non-Compliance	Off-topic, Bad instruction following	35
	Knowledge Gap	Assumptions, Lack of data, Hallucinated facts, Wrongly cited	28
	Logical Error	Lack of common sense, Reasoning error	28
	Linguistic Error	Fluency, Grammatical errors, False pronouns	23
	None of these	No problem drift	29
	Other	Any other error	8

Table 3: Error types that occur with problem drift. Eight human experts assessed a total of 170 discussion excerpts to determine how frequently each error type occurs.

DRIFTJudge와 DRIFTPolicy는 실제로 도움이 되나?

- DRIFTJudge
 - specificity 0.92, recall 0.57, precision 0.15
→ 보수적이지만 아직 약함
- DRIFTPolicy는 drift 사례의 30.6%를 완화
- 약한 모델에서는 정확도 하락폭을 -3.66%에서 -0.08%까지 줄임

Mitigation	Drift	Never Drift	Ratio
None (MAD)	49.0 $\pm$ 2.2	324.0 $\pm$ 2.2	86.9% $\pm$ 0.6
DRIFTPolicy	39.7 $\pm$ 6.2	333.3 $\pm$ 6.2	89.4% $\pm$ 1.7
Regenerate	35.7 $\pm$ 2.1	337.3 $\pm$ 2.1	90.4 % $\pm$ 0.6

Table 4: Number of samples on MMLU-Pro listed by mitigation method that show or never show problem drift during MAD. The last column refers to the percentage of never drifting out of all samples. Better values are displayed in bold. MAD uses *Llama-3.1* and Voting.

Conclusion

- 멀티에이전트 토론은 “길수록 좋다”가 아니라 “집중을 유지할 때만 좋다.”
- 이 논문은 그 집중 상실을 problem drift로 개념화하고 측정했다.
- 핵심 원인은 반복, 저품질 피드백, 불명확성이다.
- DRIFTJudge와 DRIFTPolicy는 robust MAD를 위한 출발점이다.

내가 생각하는 논문 Review

- 강점: 평균 성능이 아니라 토론 내부 붕괴 과정을 분석
- 강점: FOCUS라는 명확한 계량 지표 + 인간 annotation 결합
- 약점: 인간 평가는 drifting turn과 직전 turn만 봐서 전체 히스토리 손실 가능
- 약점: DRIFTJudge+DRIFTPolicy는 계산비용 8.5% 증가, 완화도 부분적임

Open Question

- 더 긴 memory를 주면 drift가 줄까? 주관적 생성에서 drift와 창의적 탐색은 어떻게 구분할까?